

大模型智能网管-基于历史请求学习的模型路由分发系统

命题企业：华为技术有限公司

命题组别：国产操作系统软件组

【命题背景】 随着企业大规模部署多种大模型（如 DeepSeek-V3、Qwen-Max、GPT-4o 等），如何为每个用户请求选择最优模型成为一个核心挑战。传统方案存在明显缺陷： - 单一最强模型：成本高（如 GPT-4o 价格是小型模型的 30 倍），且对简单任务过度消耗。 - 固定规则路由：无法适应请求分布的变化，缺乏自适应性。 - 忽略历史信息：用户的请求模式、任务类型偏好等历史数据未被有效利用。 本命题要求设计一套智能网管系统，通过分析历史请求数据（请求内容、响应质量、延迟、成本），学习最优路由策略，将新请求分发到最合适的模型上，在满足质量约束的前提下最小化成本与延迟。

【命题内容】 设计一个智能体网管系统，基于历史请求数据训练/优化一个轻量级路由器，实现对新请求的智能分发。 已知条件： - 大模型集群包含 M 个不同模型（ $M=5\sim10$ ），每个模型有已知的：单位成本、平均延迟、擅长任务类型标签 - 历史请求数据集 $D = \{(query_i, model_j, quality_score_i, latency_i, cost_i)\}$ ，包含 N 条记录 - 对新请求 $query_new$ ，系统需输出最优目标模型 $model^*$ 优化目标（按优先级）： - 质量约束优先：模型响应质量不低于用户阈值（如质量分 ≥ 0.8 ） - 成本最小化：在满足质量的前提下选择最便宜的模型 - 延迟优化：同等质量与成本下，选择延迟最低的模型

【答题要求】 - 系统需运行在鲲鹏 CPU 服务器上，需充分利用鲲鹏的 NEON 指令集和多核并行能力进行推理加速； - 利用历史数据，设计具体路由决策算法，给定请求特征与在线模型性能估算，选择最优模型； - 一份逻辑清晰的技术方案文档，包含特征设计表、路由器架构图、核心算法伪代码

【命题详细解读】: [大模型智能网管-基于历史请求学习的模型路由分发系统 · 国创赛 2026 - AtomGit AI 社区](#)